

数据分析大作业：人口统计与经济因素对个人收入的影响-分析

1. 作业目标

本次作业旨在帮助同学们在真实的人口普查数据情境中，全面锻炼数据清洗、多维度分析和可视化呈现能力。通过对个人收入数据集的探索，学习如何从复杂数据中提炼洞察，并形成有逻辑的分析报告。

- 强化数据分析基础：** 掌握缺失值/异常值处理、描述性统计和多字段交叉分析的方法。
- 深化洞察力：** 结合可视化图表（至少 **3种**）揭示人口统计特征（如教育、婚姻、年龄）与经济表现（如薪资、资本收益）之间的深层关系。
- 奠定建模基础：** 理解特征工程在预测任务中的作用，并完成基础分类模型的构建与结果解释。

2. 数据集介绍

- 数据集：** 基于美国人口普查（Census-Income/Adult）数据集的训练集 (train.csv)。
- 主题：** 分析各种人口统计和工作相关特征，预测个人年收入是否超过 \$50,000。
- 列描述（关键部分）：**
 - * `income`: 目标变量，收入标签（`<=50K` 或 `>50K`）。
 - * `age`: 年龄。
 - * `education`: 教育程度。
 - * `hours_per_week`: 每周工作时长。
 - * `marital_status`: 婚姻状况。
 - * `occupation`: 职业。
 - * `relationship`: 关系状态。
 - * `race`: 种族。
 - * `sex`: 性别。
 - * `capital_gain` / `capital_loss`: 资本收益/损失。

3. 作业任务

主题：人口统计与经济因素对个人收入的影响分析

本次作业分为基础任务（共 70分）和进阶任务（30分），总分最高为 100分。

3.1 基础任务(共70分)

A. 数据预处理与概览 (30分)

1. 数据概览与清洗 (10分):
- * 加载 `train.csv`，检查所有列的数据类型、统计行数。

* 识别数据中是否有缺失值或异常值。

* 清晰说明你对这些缺失值和明显异常值（如发现）的处理方法（如删除、填充等），并执行处理。
2. 描述性统计与目标变量分析 (20分):
- * 对关键数值型字段（如 `age`, `hours\_per\_week`）进行描述性统计。

* 对目标变量 `income` 进行频次统计，计算高收入人群的比例，并用柱状图或饼图进行可视化，指出该分类问题的类别不平衡性。

B. 指定子主题分析 (40分, 每项 20分, 3选2)

请选择以下三个子主题中的任意2个进行深入分析和可视化：

编号	子主题	列组合推荐	分析方向与可视化要求
1	教育与工作付出的关系	education + hours_per_week + income	相关性分析： 分析不同教育水平 (education) 群体，其平均每周工作时长 (hours_per_week) 的分布差异。通过可视化，讨论高学历是否必然伴随更高的工作时长,并结合收入进行对比。
2	婚姻状况与收入的关系		可视化分析： 分析 marital-status 与 income

		marital-status + income	之间的关系。探索稳定的婚姻关系是否有助于提高收入。
3	年龄、性别与工作付出	age + sex + hours_per_week+ income	结构分析： 分析不同 age 和 sex 在 hours_per_week和 income中的分布中的分布。探索男女在职场中的工作特点，是否存在。

3.2 进阶任务 (30分)

根据个人的各种特征（如年龄、教育程度、职业、每周工作时长、婚姻状况等）来预测其年收入-是否超过一个设定的阈值（例如 \$50,000）：

要求使用的方法/模型（二选一）：

- 1. 逻辑回归。

2. 决策树。

要求说明选择该方法的原因，并详细解释模型运算流程和参数设置。

4. 作业要求

类别	要求说明
提交形式	提交一份分析数据的代码文件（.py 或 .ipynb，附上简单的文字结论）。
可视化	需要使用至少 2种 不同类型的图表进行辅助-说明。
作业形式	本次作业以个人形式完成。